



Facultad de Informática y Ciencias Aplicadas
Escuela de Informática

Asignatura: Técnicas de Producción Industrial de Software II

Sección: 01

Docente: Ing. Jorge Machado

Actividad: Caso Práctico Aplicado

Alumno: Humberto Asael Parada Flores

Carne: 25-1077-2022

San Salvador, 11 de Mayo de 2026

Introducción.

El presente análisis tiene como objetivo aplicar técnicas de minería de datos utilizando Python y Google Colab sobre el dataset “Prestige_modificado.csv”. El propósito es comprender cómo variables como educación, ingresos, participación femenina y tipo ocupacional se relacionan con el prestigio de diferentes ocupaciones.

Desde la perspectiva de producción industrial de software, este análisis representa un flujo completo de trabajo basado en datos: carga, limpieza, validación, análisis exploratorio, modelado, interpretación y generación de conclusiones orientadas a la toma de decisiones.

Objetivo general

Analizar relaciones entre variables ocupacionales utilizando técnicas de análisis de datos y clusterización en Python.

Objetivos específicos

- Preparar y validar el dataset.
- Identificar relaciones entre variables mediante correlación.
- Visualizar tendencias entre educación, ingresos y prestigio.
- Aplicar K-Means para segmentar ocupaciones.
- Interpretar resultados desde un enfoque de producción industrial de software.

1. Preparación e inspección inicial del dataset

Codigo Python en Google Colab

```
import pandas as pd

# Cargar dataset
# IMPORTANTE: el archivo usa ; como separador

df = pd.read_csv('Prestige_modificado.csv', sep=';')

# Mostrar dimensiones
print(df.shape)

# Primeras filas
print(df.head())

# Información general
print(df.info())

# Valores nulos
print(df.isnull().sum())

# Duplicados
print(df.duplicated().sum())

# Estadísticas descriptivas
print(df.describe())
```

Resultados obtenidos

1.1. Dimensiones del dataset.

El dataset contiene:

- 102 registros
- 7 columnas

1.2. Variables encontradas.

Variable	Tipo
occupation	object
education	float
income	int
women	float
prestige	float
census	int
type_num	int

1.3. Información general.

 `df.describe()`

...	education	income	women	prestige	census	type_num
count	102.000000	102.000000	102.000000	102.000000	102.000000	102.000000
mean	10.738039	6797.901961	28.979020	46.833333	5401.774510	1.843137
std	2.728444	4245.922227	31.724931	17.204486	2644.993215	0.817447
min	6.380000	611.000000	0.000000	14.800000	1113.000000	0.000000
25%	8.445000	4106.000000	3.592500	35.225000	3120.500000	1.000000
50%	10.540000	5930.500000	13.600000	43.600000	5135.000000	2.000000
75%	12.647500	8187.250000	52.202500	59.275000	8312.500000	2.000000
max	15.970000	25879.000000	97.510000	87.200000	9517.000000	3.000000

1.4. Calidad de datos.

- No se encontraron valores nulos.
- No se encontraron registros duplicados.
- Los tipos de datos son adecuados para análisis.
- Las variables numéricas están correctamente reconocidas.

1.5. Resumen.

El dataset se encuentra en buenas condiciones para realizar análisis. No fue necesario eliminar registros ni aplicar procesos complejos de limpieza. Esto permite trabajar con información consistente y facilita la reproducibilidad del análisis en Python.

2. Análisis de relación.

Código Python en Google Colab.

```
# Seleccionar variables numéricas
variables_numericas = df.select_dtypes(include=['int64', 'float64'])

# Matriz de correlación
matriz_correlacion = variables_numericas.corr()


# Mostrar matriz
print(matriz_correlacion.round(3))

# Correlaciones respecto a prestige
print(matriz_correlacion['prestige'].sort_values(ascending=False).round(3))
```

2.1. Resultados.

Matriz de correlación.

	education	income	women	prestige	census	type_num
education	1.000	0.578	0.062	0.850	-0.823	-0.382
income	0.578	1.000	-0.441	0.715	-0.361	-0.368
women	0.062	-0.441	1.000	-0.118	-0.227	0.251
prestige	0.850	0.715	-0.118	1.000	-0.635	-0.465
census	-0.823	-0.361	-0.227	-0.635	1.000	0.288
type_num	-0.382	-0.368	0.251	-0.465	0.288	1.000



Matriz de correlación respecto a Prestige.

```
prestige    1.000
education   0.850
income      0.715
women       -0.118
type_num    -0.465
census      -0.635
Name: prestige, dtype: float64
```

2.2. Interpretación y explicación de correlaciones.

Las variables con mayor relación positiva con el prestigio ocupacional son:

Variable	Relación aproximada
education	Muy fuerte positiva
income	Fuerte positiva
type_num	Moderada

- A mayor nivel educativo, mayor prestigio ocupacional.
- Las ocupaciones con mayores ingresos tienden a ser mejor valoradas socialmente.
- Algunos tipos ocupacionales presentan más prestigio que otros.

La variable women presenta una relación más débil y ligeramente negativa, lo cual podría reflejar desigualdades históricas o diferencias estructurales entre ocupaciones.

Los resultados son coherentes desde un punto de vista social y laboral.

Generalmente, ocupaciones que requieren más formación académica y ofrecen mayores ingresos suelen recibir mayor valoración social. Sin embargo, es importante aclarar que correlación no significa causalidad. El hecho de que dos variables estén relacionadas no implica que una cause directamente la otra.

3. Visualización de resultados.


3.1. Education vs Prestige.

3.1.1. Código Python.

```
import matplotlib.pyplot as plt

plt.figure(figsize=(7,5))
plt.scatter(df['education'], df['prestige'])
plt.xlabel('Education')
plt.ylabel('Prestige')
plt.title('Relación entre educación y prestigio')
plt.grid(True)
plt.show()
```


3.1.2. Grafica.



3.1.3. Interpretación.

La gráfica muestra una tendencia positiva clara entre educación y prestigio.

Las ocupaciones con mayor nivel educativo suelen presentar niveles más altos de prestigio.


Esto indica que la formación académica es un factor importante en la valoración social de los perfiles profesionales.

3.2. Income vs Prestige.

3.2.1. Código Python.

```
plt.figure(figsize=(7,5))
plt.scatter(df['income'], df['prestige'])
plt.xlabel('Income')
plt.ylabel('Prestige')
plt.title('Relación entre ingreso y prestigio')
plt.grid(True)
plt.show()
```

3.2.2. Grafica.



3.2.3. Interpretación.

Existe una relación positiva entre ingresos y prestigio ocupacional. A medida que aumentan los ingresos promedio, también tiende a aumentar el prestigio.

Sin embargo, se observan algunos casos atípicos donde ciertas ocupaciones tienen ingresos relativamente altos, pero prestigio moderado.

3.3. Prestigio por tipo ocupacional.

3.3.1. Código Python.


```
plt.figure(figsize=(7,5))

# Promedio de prestigio por tipo
promedio = df.groupby('type_num')['prestige'].mean()

promedio.plot(kind='bar')

plt.xlabel('Tipo ocupacional')
plt.ylabel('Prestigio promedio')
plt.title('Prestigio promedio por tipo ocupacional')
plt.grid(True)
plt.show()
```

3.3.2. Grafica.



3.3.3. Interpretación.

Los perfiles profesionales y técnicos presentan mayor prestigio promedio que ocupaciones operativas o administrativas.

Esto puede relacionarse con el nivel educativo requerido y el nivel de especialización asociado a cada tipo ocupacional.

4. Análisis de agrupación con K-Means.

Código Python.

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

# Variables seleccionadas
columnas_cluster = ['education', 'income', 'women', 'prestige',
                    'type_num']

X = df[columnas_cluster].copy()

# Escalamiento
escalador = StandardScaler()
X_escalado = escalador.fit_transform(X)

# Modelo con 4 clusters
modelo_k4 = KMeans(n_clusters=4, random_state=42, n_init=10)
df['Cluster_4'] = modelo_k4.fit_predict(X_escalado)

# Modelo con 5 clusters
modelo_k5 = KMeans(n_clusters=5, random_state=42, n_init=10)
df['Cluster_5'] = modelo_k5.fit_predict(X_escalado)

# Centroides promedio
print(df.groupby('Cluster_4')[columnas_cluster].mean().round(2))
print(df.groupby('Cluster_5')[columnas_cluster].mean().round(2))
```

Resultado.

	education	income	women	prestige	type_num
Cluster_4					
0	13.59	7329.35	36.35	63.33	0.95
1	8.82	5878.74	9.60	37.26	2.09
2	10.12	3545.04	74.16	37.76	2.57
3	14.69	15746.83	6.00	74.23	1.00
	education	income	women	prestige	type_num
Cluster_5					
0	10.94	3909.12	73.76	41.50	2.88
1	9.31	6922.03	5.84	42.18	2.25
2	13.59	7329.35	36.35	63.33	0.95
3	7.78	3327.48	34.10	26.87	1.71
4	14.69	15746.83	6.00	74.23	1.00

Interpretación de clústeres.

4.1. Modelo con 4 clústeres

El modelo de 4 grupos permite identificar segmentos ocupacionales amplios y fáciles de interpretar:

Clúster 1

- Alto nivel educativo
- Altos ingresos
- Alto prestigio

Representa ocupaciones profesionales y gerenciales altamente valoradas.

Clúster 2

- Nivel medio educativo
- Ingresos moderados
- Prestigio medio

Incluye ocupaciones administrativas o técnicas intermedias.

Clúster 3

- Menor educación
- Menores ingresos
- Menor prestigio

Corresponde principalmente a ocupaciones operativas.

Clúster 4

- Alta participación femenina
- Prestigio medio
- Ingresos variables

Representa perfiles con características sociales diferenciadas.

4.2. Modelo con 5 clústeres

El modelo de 5 grupos ofrece una segmentación más detallada. Permite distinguir ocupaciones especializadas que en el modelo anterior quedaban agrupadas. Sin embargo, algunos grupos quedan demasiado pequeños y difíciles de interpretar desde una perspectiva gerencial.

4.3. Justificación para el modelo más útil.

El modelo con 4 clústeres resulta más útil para interpretar el caso.

Razones:

- Los grupos son más claros.
- La interpretación es más sencilla.
- Facilita la toma de decisiones organizacionales.
- Reduce complejidad innecesaria.

5. Interpretación orientada a producción industrial de software.

5.1. ¿Qué variables tienen mayor relación con el prestigio?

Las variables con mayor relación son:

- Educación
- Ingresos
- Tipo ocupacional

Esto sugiere que la especialización técnica y el nivel de formación tienen gran influencia en la valoración de los perfiles profesionales.

5.2. ¿Cómo podría una empresa de software usar este análisis?

Una empresa de software podría utilizar este tipo de análisis para:

- Identificar perfiles estratégicos.
- Diseñar planes de formación.
- Definir rutas de crecimiento profesional.
- Evaluar brechas salariales.
- Detectar áreas de alta especialización.
- Mejorar asignación de talento.
- Analizar equidad de género en roles técnicos.

También puede servir para optimizar procesos de contratación y desarrollo organizacional.

5.3. ¿Qué grupos de ocupaciones se identificaron?

Se identificaron grupos con características diferenciadas:

- Perfiles altamente especializados.
- Ocupaciones técnicas intermedias.
- Roles operativos.
- Ocupaciones con fuerte presencia femenina.

Estos grupos permiten segmentar estrategias de capacitación y gestión de talento.

5.4. ¿Existen resultados anómalos?

Sí. Según el análisis algunas ocupaciones presentan:

- Ingresos altos con prestigio moderado.

- Prestigio relativamente alto con ingresos medios.

Esto indica que el prestigio social no depende exclusivamente del salario.

También pueden influir factores culturales, históricos o sociales.

5.5. ¿Qué información adicional sería útil?

Sería útil contar con información acerca de:

- Años de experiencia.
- Nivel de especialización técnica.
- Certificaciones.
- Satisfacción laboral.
- Productividad.
- Ubicación geográfica.
- Tamaño de empresa.
- Demanda del mercado laboral.

Esto permitiría construir modelos más completos y precisos.

Conclusiones.

El análisis permitió identificar relaciones importantes entre educación, ingresos y prestigio ocupacional.

La variable educación mostró la relación más fuerte con el prestigio, lo cual evidencia la importancia de la formación académica en la valoración de perfiles profesionales.

Las técnicas de clusterización permitieron segmentar ocupaciones en grupos con características similares, facilitando la interpretación estratégica de los datos.

Desde la perspectiva de producción industrial de software, este tipo de análisis puede apoyar decisiones relacionadas con: Gestión de talento, formación técnica, especialización, organización de roles, optimización de procesos y planeación de carrera.

Recomendaciones.

- Incorporar más variables relacionadas con desempeño laboral.
- Evaluar modelos predictivos adicionales.
- Aplicar análisis de clasificación.
- Integrar dashboards interactivos.
- Automatizar el flujo analítico.
- Mantener control de calidad sobre los datos.

Repositorio: https://github.com/AsaelP25/Caso_Practico-2510772022.git